

Tarefa 1: Classificação

Resgate de Vítimas de Catástrofes Naturais, Desastres ou Grandes Acidentes

Objetivo da tarefa

Construir um modelo de classificação com CART e outro com Redes Neurais MLP (RN): dadas as características de **entrada de 1 a 10** conforme a tabela 1, o modelo aprendido deve aprender a classificar o estado de uma vítima que corresponde à característica **13 (tri)**. A característica **tri** vem do protocolo START (*Simple Triage and Rapid Treatment*) utilizado para classificar uma vítima de acordo com as cores:

- **verde** (0): ferimentos leves que não representam risco à vida
- **amarela** (1): ferimentos graves; podem aguardar um pouco
- **vermelha** (2): ferimentos críticos; requerem tratamento imediato para sobreviver
- **preta** (3): salvamento inviável; morto

Seq	Variável	Descrição	Tipo
1	idade	Idade da vítima (entre 1 e 90 anos)	INT
2	fc	Frequência cardíaca (bpm) de 0 a 200	INT
3	fr	Frequência respiratória (rpm) de 0 a 50	INT
4	pas	Pressão arterial sistólica (mmHg) de 0 a 220	INT
5	spo2	Saturação de oxigênio (%) de 0 a 100	INT
6	temp	Temperatura corporal (°C) de 0 a 43	FLOAT
7	pr	pulso radial: 0 (NÃO), 1 (SIM)	INT
8	sg	sangramento: 0 (NÃO), 1 (LEVE), 2 (MODERADO), 3 (GRAVE)	INT
9	fx	fratura exposta: 0 (NÃO), 1 (SIM)	INT
10	queim	queimadura: 0 (NÃO), 1 (LEVE), 2 (MODERADO), 3 (GRAVE)	INT
11	gcs	Escala de Coma de Glasgow (3–15)	INT
12	avpu	Estado de consciência: 0 (ALERTA), 1 (VOZ), 2 (PAIN), 3 (INCONSCIENTE)	INT
13	tri	Triagem classif. START: 0 (verde), 1 (amarelo), 2 (vermelho), 3 (preto)	INT
14	sobr	Prob. de sobrevivência (0 a 1) REAL	FLOAT

Tabela 1: Características de entrada para o classificador de 1 a 10. A saída a ser predita é a 13 (tri). As características 11, 12 e 14 não podem ser utilizadas nesta tarefa. Fonte: [projeto VictSim3](#)

Requisitos

1. **Não é permitido utilizar** as seguintes características **como variáveis de entrada** do treinamento: 11 gcs, 12 avpu, 13 tri e 14 sobr.
2. A variável de saída a ser predita é: **13 tri**
3. Utilizar validação cruzada no treinamento

Você pode se inspirar nos códigos disponíveis no Google Colab: [Classificador CART](#)

Procedimento

TREINAMENTO/VALIDAÇÃO

- 1) Gere um **dataset somente para treinamento/validação** com o programa gerar_dados_vitimas.py
O número de vítimas deve ser **10.000 vítimas** (utilize uma semente fixa para fins de reprodutibilidade).
 - a. Descreva os parâmetros de criação do dataset: número de vítimas, idade, desvio padrão, ruído e tipo de acidente.
 - b. Defina o número de *folds* utilizado para realizar a validação cruzada
- 2) **Treine o CART com** o dataset de treinamento/validação com validação cruzada.
 - a. utilize 3 (três) hiperparametrizações distintas variando *max_depth*, *min_samples_leaf*, *criterion* ou outras a sua escolha; uma deve ser subajustada (U), outra equilibrada (E) e a terceira, sobreajustada (O).
 - b. salve o f1-score médio de treino e de validação de cada hiperparametrização
- 3) **Treine a RN** com o dataset de treinamento/validação com validação cruzada.
 - a. utilize 3 hiperparametrizações variando o número de *camadas ocultas*, *número de neurônios/camada*, *função de ativação*, *taxa de aprendizado* ou outras a sua escolha;
 - b. salve o valor de f1-score de treino e de validação para cada hiperparametrização
- 4) **Compare** os resultados dos modelos CART x modelos de RN.
 - a. **Viés:** compare o f1 macro médio de treino com o f1 macro médio de validação dos modelos gerados para subsidiar a escolha do melhor modelo CART e do melhor modelo RN:
f1 de uma classe: $f_{1_c} = \frac{2PR}{(P+R)}$ sendo $P = \text{precisão}$ e $R = \text{recall}$
f1 macro (todas as classes): $f_1 = (1/C) \cdot \sum_{i=1}^C f_{1_i}$ sendo C o número de classes
f1 macro médio (sobre os k folds): $\bar{f}_1 = \frac{1}{k} \sum_{j=1}^k f_{1_j}$ sendo k o número de folds

TESTES CEGOS

- 5) **Retreino:** com a melhor hiperparametrização de CART e a melhor da RN, retreine os modelos com todo o dataset gerado na etapa 1 (sem utilizar validação cruzada ou split (fazer o fit com as 10.000 amostras)
Teste cego: com o dataset de **teste cego (1300v)**, compare os **valores de precisão, recall e f1-score** do modelo CART x modelo RNs produzidos na etapa 5. Use o dataset de teste cego somente neste item, se este dataset foi usado na etapa de treino/validação ou de retreino, configura-se vazamento de dados (*data leakage*) e o teste cego perde a validade.

RELATÓRIO

O relatório deve conter unicamente o que segue sem nenhum texto adicional. Eliminar todos os comentários em cinza.

1) DATASET DE TREINAMENTO/VALIDAÇÃO

MODELO	VALOR
Vítimas tri=verde	<número>
Vítimas tri=amarelo	<número>
Vítimas tri=vermelho	<número>
Vítimas tri=preto	<número>
Idade das vítimas	<idade>
Desvio padrão amostral da idade	<dpa>
ruído	0 < ruído <= 0.05

(os valores são ilustrativos, com exceção do número de vítimas; os demais podem ser alterados)

(os valores são ilustrativos, com exceção do número de vítimas; os demais podem ser alterados)

2) HIPERPARAMETRIZAÇÕES CART

MODELO	U	E	O
Min_samples_leaf	<valor>	<valor>	<valor>
Max_depth	<valor>	<valor>	<valor>
Criterion (gini, ent)	<valor>	<valor>	<valor>

(as linhas acima são obrigatórias mesmo que sejam postos os valores defaults; outras linhas podem ser adicionadas de acordo com as escolhas)

3) RESULTADOS DOS MODELOS CART

MODELO	U	E	O
TREINO $\bar{f}_1$ (DPA)	0.88212 (0.01074)	$\bar{f}_1$ (dpa)	$\bar{f}_1$ (dpa)
VALIDAÇÃO $\bar{f}_1$ (DPA)	0.87459 (0.01185)	$\bar{f}_1$ (dpa)	$\bar{f}_1$ (dpa)
MÉDIA DAS DIFS. (DPA)	0.00753 (0.00469)	$\bar{f}_1$ (dpa)	$\bar{f}_1$ (dpa)

Observe que é para usar o f_1 macro médio (média de f_1 de todos os k folders).

Exemplo: vamos supor que para o CART 1, com 3 folds ($k=3$), obtivemos os seguintes valores:

Treino: F1 por fold: [0.86710, 0.88764, 0.89162] média=0.88212 dpa=0.01074

Validação: F1 por fold: [0.85837, 0.88636, 0.87903] média=0.87459 dpa=0.01185

Diferenças abs.....: [0.00873, 0.00128, 0.01258] média=0.00753 dpa=0.00469

4) HIPERPARAMETRIZAÇÕES REDE NEURAL

MODELO	U	E	O
Topologia	[3 3 3]	[5 5 5 8 8 8]	[10 10 10 10 10 10 10]
Função de ativação	tanH		
Learning rate	0.03		
solver	sgd		

(as linhas acima são obrigatórias sendo seus valores ilustrativos; a topologia apresenta o número de neurônios por camada escondida; outras linhas podem ser adicionadas de acordo com as escolhas)

5) RESULTADOS DOS MODELOS RN

MODELO	U	E	O
TREINO $\bar{f}_1$ (DPA)	0.88212 (0.01074)	$\bar{f}_1$ (dpa)	$\bar{f}_1$ (dpa)
VALIDAÇÃO $\bar{f}_1$ (DPA)	0.87459 (0.01185)	$\bar{f}_1$ (dpa)	$\bar{f}_1$ (dpa)
MÉDIA DAS DIFS. (DPA)	0.00753 (0.00469)	$\bar{f}_1$ (dpa)	$\bar{f}_1$ (dpa)

6) MELHOR MODELO CART X MELHOR MODELO RN

MODELO	Melhor CART (_)	Melhor RN (_)
TREINO $\bar{f}_1$ (DPA)	0.88212 (0.01074)	$\bar{f}_1$ (dpa)
VALIDAÇÃO $\bar{f}_1$ (DPA)	0.87459 (0.01185)	$\bar{f}_1$ (dpa)
MÉDIA DAS DIFS. (DPA)	0.00753 (0.00469)	$\bar{f}_1$ (dpa)

7) RESULTADOS DO TESTE CEGO MELHOR CART X MELHOR RN

MODELO	Melhor CART (_)	Melhor RN (_)
MÉDIA PRECISÃO (macro)		
MÉDIA RECALL (macro)		
F1 SCORE (macro)		
ACURÁCIA		

8) MATRIZ DE CONFUSÃO DO MELHOR CART e MATRIZ DE CONFUSÃO DA MELHOR RN

G=verde, Y=amarelo, R=vermelho, B=preto

CART	RN
G Y R B	G Y R B
real G	real G
real Y	real Y
real R	real R
real B	real B
predito	predito

ENTREGA

SOMENTE NO MOODLE (NÃO ENVIAR POR EMAIL)

- Relatório em PDF
- Códigos fonte
- Modelos:
 - cart nomeado: melhor_cart.joblib
 - RN nomeado: melhor_rn.joblib