

Tarefa 2: Regressão

Resgate de Vítimas de Catástrofes Naturais, Desastres ou Grandes Acidentes

Objetivo da tarefa

Construir um modelo de regressão com CART e outro, com Redes Neurais MLP (RN): dadas as características **de entrada de 1 a 10** conforme a tabela 1, o modelo deve aprender a estimar a probabilidade de sobrevivência de uma vítima representado pela característica **14 (sobr)**. Essa característica é um número real no intervalo [0, 1], sendo zero a menor probabilidade de sobrevivência e 1, a maior.

Seq	Variável	Descrição	Tipo
1	idade	Idade da vítima (entre 1 e 90 anos)	INT
2	fc	Frequência cardíaca (bpm) de 0 a 200	INT
3	fr	Frequência respiratória (rpm) de 0 a 50	INT
4	pas	Pressão arterial sistólica (mmHg) de 0 a 220	INT
5	spo2	Saturação de oxigênio (%) de 0 a 100	INT
6	temp	Temperatura corporal (°C) de 0 a 43	FLOAT
7	pr	pulso radial: 0 (NÃO), 1 (SIM)	INT
8	sg	sangramento: 0 (NÃO), 1 (LEVE), 2 (MODERADO), 3 (GRAVE)	INT
9	fx	fratura exposta: 0 (NÃO), 1 (SIM)	INT
10	queim	queimadura: 0 (NÃO), 1 (LEVE), 2 (MODERADO), 3 (GRAVE)	INT
11	gcs	<u>Escala de Coma de Glasgow (3-15)</u>	INT
12	avpu	Estado de consciência: 0 (ALERTA), 1 (VOZ), 2 (PAIN), 3 (INCONSCIENTE)	INT
13	tri	Triagem classif. START: 0 (verde), 1 (amarelo), 2 (vermelho), 3 (preto)	INT
14	sobr	Prob. de sobrevivência (0 a 1) REAL	FLOAT

Tabela 1: Características de entrada para o classificador de 1 a 10. A saída a ser predita é a 14 (sobr). As características 11, 12 e 13 não podem ser utilizadas nesta tarefa. Fonte: [projeto VictSim3](#)

Requisitos

1. **Utilizar o formato do dataset** de treinamento que está descrito [aqui](#).
2. **Não é permitido utilizar** as seguintes características **como variáveis de entrada** do treinamento: 11 gcs, 12 avpu, 13 tri e 14 sobr.
3. **A variável de saída a ser predita é:** 14 sobr

Você pode se inspirar nos códigos disponíveis no Google Colab:

[Regressor CART](#)

[Regressor rede neural MLP](#)

Procedimento e relatório

TREINAMENTO/VALIDAÇÃO

- 1) Gere um dataset de treinamento/validação com exatamente 10.000 vítimas com o programa `gerar_dados_vitimas.py`.
 - a. Descreva os parâmetros de criação do dataset: número de vítimas, idade, desvio padrão e ruído.
 - b. Defina o número de *folds* utilizado para realizar a validação cruzada
- 2) **Treine o CART com** o dataset de treinamento/validação com o método da validação cruzada.
 - a. utilize 3 (três) hiperparametrizações distintas sendo que uma delas deve gerar um **modelo** subajustado ou underfitted (U), outra, um **modelo** sobreajustado ou **overfitted (O)** e a terceira, um modelo **equilibrado (E)** de baixa taxa de erro e boa capacidade de generalização. Varie os hiperparâmetros como `max_depth`, `min_samples_leaf` ou outras a sua escolha.
 - b. salve o erro quadrático médio ($\overline{MSE}$) de treino e de validação de cada hiperparametrização.
- 3) **Treine uma RN MLP** com o dataset de treinamento/validação com validação cruzada.
 - a. utilize 3 (três) hiperparametrizações distintas sendo que uma delas deve gerar um **modelo** subajustado ou underfitted (U), outra, um **modelo** sobreajustado ou **overfitted (O)** e a terceira, um modelo **equilibrado (E)** de baixa taxa de erro e boa capacidade de generalização. Varie o número de *camadas ocultas*, *número de neurônios/camada*, *função de ativação*, *taxa de aprendizado* ou outros hiperparâmetros a sua escolha;
 - b. salve o valor de $\overline{MSE}$ de treino e de validação de cada hiperparametrização.
- 4) **Compare** os resultados dos modelos CART x modelos de RN.
 - a. **Viés:** compare o MSE médio de treino com o MSE médio de validação para subsidiar a escolha do melhor modelo CART e do melhor modelo de RN.

$$\overline{MSE} = \frac{1}{k} \sum_{j=1}^k MSE_j \quad (\text{média dos MSE dos k-folds})$$

$$MSE_i = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

onde:

n = número de observações (exemplos utilizados no treinamento ou na validação por fold)

y_i = valor **real** da variável de saída para o indivíduo i

$\hat{y}_i$ = valor **predito** pelo modelo para o indivíduo i

$e_i = (y_i - \hat{y}_i)^2$ = erro quadrático de predição para o indivíduo i

TESTES CEGOS

- 5) **Retreino:** com a melhor hiperparametrização de CART e a melhor da RN, retreine os modelos com todo o dataset gerado na etapa 1 (sem utilizar validação cruzada ou split (fazer o fit com as 10.000 amostras)).
- 6) **Teste cego:** com o dataset de teste cego de [1300 vítimas](#) compare os **valores de MSE** do modelo CART x modelo RN produzidos na etapa de retreino (5). **Use o dataset de teste cego somente neste item**, se for usado em qualquer outra etapa de treino/validação, configura-se vazamento de dados (*data leakage*).

RELATÓRIO

O relatório deve conter unicamente o que segue sem nenhum texto adicional. Eliminar todos os comentários em cinza.

1) DATASET DE TREINAMENTO/VALIDAÇÃO

MODELO	VALOR
Vítimas tri=verde	<número>
Vítimas tri=amarelo	<número>
Vítimas tri=vermelho	<número>
Vítimas tri=preto	<número>
Idade das vítimas	<idade>
Desvio padrão amostral da idade	<dpa>
ruído	0 < ruído <= 0.05

(os valores são ilustrativos, com exceção do número de vítimas; os demais podem ser alterados)

2) HIPERPARAMETRIZAÇÕES CART

MODELO	U	E	O
Min_samples_leaf	<valor>	<valor>	<valor>
Max_depth	<valor>	<valor>	<valor>
<outras>	<valor>	<valor>	<valor>

(as linhas acima são obrigatórias mesmo que sejam postos os valores defaults; outras linhas podem ser adicionadas de acordo com as escolhas)

3) RESULTADOS DOS MODELOS CART

Médias dos MSEs com desvio padrão amostral por fold por hiperparametrização (U, E, O)

MODELO	CART U	CART E	CART O
TREINO $\overline{MSE}$ (dpa)	0,0147 (0,0119)	<média> (<dpa>)	<média> (<dpa>)
VALIDAÇÃO $\overline{MSE}$ (dpa)	0,0707 (0,0011)	<média> (<dpa>)	<média> (<dpa>)
MÉDIA DAS DIFS. (dpa)	0,0560 (0,01139)	<média> (<dpa>)	<média> (<dpa>)

Observe que é para usar o $\overline{MSE}$ (média dos MSEs de todos os k folders).

Exemplo: vamos supor que para o CART U, com 3 folds (k=3), obtivemos os seguintes valores:

Treino MSE por fold: [0.0232, 0.0011, 0.0198] média=0.0147 dpa=0.0119

Validação MSE por fold: [0.0721, 0.0703, 0.0699] média=0.0707 dpa=0.0011

Diferença absoluta MSE: [0.0489, 0.0692, 0.0501] média=0.0560 dpa=0.01139

4) HIPERPARAMETRIZAÇÕES REDE NEURAL

MODELO	U	E	O
Topologia	[3 3 3]	[5 5 5 8 8 8]	[10 10 10 10 10 10 10]
Função de ativação	tanH		
Learning rate	0.03		
solver	sgd		

(as linhas acima são obrigatórias sendo seus valores ilustrativos; a topologia apresenta o número de neurônios por camada escondida; outras linhas podem ser adicionadas de acordo com as escolhas)

5) RESULTADOS DOS MODELOS RN

MODELO	RN U	RN E	RN O
TREINO $\overline{MSE}$ (dpa)	<média> (<dpa>)	<média> (<dpa>)	<média> (<dpa>)
VALIDAÇÃO $\overline{MSE}$ (dpa)	<média> (<dpa>)	<média> (<dpa>)	<média> (<dpa>)
MÉDIA DAS DIFS. (dpa)	<média> (<dpa>)	<média> (<dpa>)	<média> (<dpa>)

(ver explicações na tabela 3)

6) MELHOR MODELO CART X MELHOR MODELO RN

MODELO	Melhor CART (_)	Melhor RN (_)
TREINO $\overline{MSE}$ (dpa)	<média> (<dpa>)	<média> (<dpa>)
VALIDAÇÃO $\overline{MSE}$ (dpa)	<média> (<dpa>)	<média> (<dpa>)
MÉDIA DAS DIFS. (dpa)	<média> (<dpa>)	<média> (<dpa>)

(copiar os resultados das tabelas 3 e 5)

7) RESULTADOS DO TESTE CEGO: MELHOR CART X MELHOR RN

MODELO	Melhor CART (_)	Melhor RN (_)
MSE	<valor>	<valor>
Ganho % de MSE (somente para o melhor entre CART e RN)	$\left(1 - \frac{MSE_{CART}}{MSE_{RN}}\right) \times 100$ se MSE CART < MSE RN	$\left(1 - \frac{MSE_{RN}}{MSE_{CART}}\right) \times 100$ se MSE RN < MSE CART
RMSE	$\sqrt{MSE}$	$\sqrt{MSE}$
Ganho % de RMSE (somente para o melhor entre CART e RN)	$\left(1 - \frac{RMSE_{CART}}{RMSE_{RN}}\right) \times 100$ se RMSE CART < RMSE RN	$\left(1 - \frac{RMSE_{RN}}{RMSE_{CART}}\right) \times 100$ se RMSE RN < RMSE CART

8) GRÁFICO DE DISPERSÃO

Para os resultados do teste cego do CART e da RN, plote os gráficos de dispersão do valor real x valor predito (um gráfico para cada modelo).

ENTREGA

SOMENTE NO MOODLE (NÃO ENVIAR POR EMAIL)

- Relatório em PDF
- Códigos fonte
- Modelos:
 - cart nomeado: melhor_cart.joblib
 - RN nomeado: melhor_rn.joblib
 - se usou scaler na RN: scaler.joblib